

Comparaison des catalogues de donnees -- PrevisionEnergie

Contexte

Le choix d'un catalogue de donnees est un element cle du Bloc 4 (C18). Trois solutions ont ete evaluees selon les contraintes du projet : budget limite, equipe reduite, architecture Medallion, conforme RGPD.

Tableau comparatif

Critere	Apache Atlas	AWS Glue Data Catalog	Google Dataplex	Editeur
	Apache Foundation (open source)	Amazon Web Services	Google Cloud Platform	
Licence / Cout	Gratuit (Apache 2.0)	Pay-per-use (~1\$/100k objets/mois)	Pay-per-use (~variable)	
Modele de deployment	On-premise / VM / Docker	SaaS (AWS uniquement)	SaaS (GCP uniquement)	
Lock-in fournisseur	Aucun	Fort (ecosysteme AWS)	Fort (ecosysteme GCP)	
Glossaire metier	Oui (natif)	Non (via DataBrew ou externe)	Oui (Business Glossary)	
Lignage (lineage)	Oui (natif, graphe complet)	Partiel (jobs Glue seulement)	Oui (natif, multi-source)	
Classification des donnees	Oui (tags, labels, types)	Oui (classifiers, crawlers)	Oui (auto-discovery)	
Integration Delta Lake	Oui (via hooks Spark/Hive)	Oui (natif avec Glue ETL)	Oui (via BigLake)	
Integration Airflow	Oui (API REST + hooks)	Oui (opérateurs Airflow)	Oui (opérateurs Airflow)	
API REST	Oui (complete)	Oui (SDK AWS)	Oui (SDK GCP)	
Recherche / Index	Oui (Solr/Elasticsearch)	Oui (recherche integree)	Oui (recherche unifiee)	
RBAC / Securite	Oui (Ranger integration)	Oui (IAM AWS)	Oui (IAM GCP)	
Conformite RGPD	A configurer manuellement	Oui (Macie + Lake Formation)	Oui (DLP + Data Catalog)	
Complexite de mise en place	Elevee (infra a gerer)	Faible (SaaS manage)	Faible (SaaS manage)	
Communauté / Documentation	Large (Apache ecosystem)	Large (AWS ecosystem)		
Moyenne (plus recent)		Horizontale (Hadoop/K8s)	Automatique (serverless)	
Automatique (serverless)				

Analyse pour PrevisionEnergie

Pourquoi Apache Atlas a ete choisi

- Cout zero** : projet a budget contraint, pas de frais cloud recurrents
- Pas de lock-in** : le client peut migrer vers n'importe quel cloud sans changer de catalogue
- Lignage natif complet** : graphe de lignage bout en bout (Kaggle -> Bronze -> Silver -> Gold -> API), pas limite aux jobs d'un seul outil
- Glossaire metier integre** : les termes metier (consommation, DJU, region) sont documentes dans le catalogue, pas dans un outil tiers
- Coherence avec la stack** : Atlas s'integre avec Spark/Delta Lake (cible de production) et Airflow (orchestrateur)

Limites acceptees

- Complexite d'installation** : Atlas necessite une infrastructure (Kafka, HBase/Solr). Pour le projet, un export JSON simulant l'integration a ete produit (`atlas/atlas_bundle.json`)
- Pas de SaaS** : maintenance a la charge de l'equipe data, mais coherent avec la politique de l'organisation (donnees sensibles on-premise)

Dans quels cas on aurait choisi autrement

| Situation | Choix recommande | |-----|-----| |
Organisation 100% AWS, budget disponible | AWS Glue | | Organisation 100% GCP, besoin auto-discovery |
Dataplex | | Equipe reduite, besoin open-source, multi-cloud | **Atlas** (choix actuel) | | PME sans equipe infra,
besoin rapide | Dataplex (SaaS simple) |

Conclusion

Le choix d'Atlas est motive par le besoin d'indépendance technologique et la richesse fonctionnelle (lignage + glossaire). La mise en production necessiterait un deploiement Docker/K8s que le projet prepare via les fichiers at las/ mais ne deploie pas en environnement de demonstration.